

Семантическая оценка подстановок сущностей

Целевая архитектура и офлайн-пайплайн обучения

1. Задача модели

Исходный текст содержит сущность e. Мы заменяем её кандидатом c и получаем второй текст. Модель должна определить, сохранилось ли фактическое содержание высказывания, а не просто похожи ли два текста по словам.

Обозначение	Смысл	Пример
A = C[e]	исходный контекст с исходной сущностью	... met NATCA ...
B = C[c]	тот же контекст с кандидатом	... met FAA ...
preserve	сущность обозначает тот же объект или замена сохраняет смысл	NATCA → полное название
changed	объект, факт или существенная конкретность изменились	NATCA → FAA

Не требуется строить суммаризатор. Нужен локальный проверяющий модуль для конкретной подстановки внутри конкретного контекста.

Где возникает ошибка	Почему обычная похожесть текста её не решает
Alias и аббревиатура	FAA и полное название могут быть разными строками, но обозначать один объект
Близкий объект	две организации, закона или локации могут быть грамматичны и тематически близки, но менять факт
Обобщение/конкретизация	замена может быть логически односторонней и потому неэквивалентной
Числовая величина	одно число, знак, единица или дата меняют утверждение при почти неизменном тексте

2. Почему одной метки недостаточно

preserved/changed полезна как основной целевой сигнал, но она скрывает причину решения. Для сложных примеров важно понять направление логического следования между исходным и изменённым текстом.

Ситуация	$A \rightarrow B$	$B \rightarrow A$
Полная эквивалентность	entailment	entailment
Кандидат обобщает исходное	entailment	neutral
Кандидат добавляет конкретность	neutral	entailment
Другая сущность того же типа	neutral/contradiction	neutral/contradiction

Например, University of Oklahoma $\rightarrow$ the university: исходное утверждение может влечь более общее, но обратное следование уже не гарантируется. Такая пара не равна корректному alias, хотя выглядит грамматично.

Для пары A/B модель должна различать четыре независимых свойства: тождество объекта, естественность кандидата в позиции, сохранение конкретности и фактологическую совместимость. Именно поэтому один бинарный label полезен для production, но недостаточен для анализа ошибок.

3. Целевая модель: общий кодировщик и несколько голов

Один ModernBERT-кодировщик получает пару текстов и строит общее представление подстановки. Из него выходят независимые предсказания.

Компонент	Выход	Назначение
Общий encoder	представление (A, B, e, c)	учитывает полный контекст, позицию и различие сущностей
Голова сохранения смысла	preserved / changed / uncertain	основной production-score
NLI-голова A → B	entailment / neutral / contradiction	что следует из исходного текста после замены
NLI-голова B → A	entailment / neutral / contradiction	не потерялась ли исходная конкретность
Ranking loss	score(positive) > score(hard negative)	раздвигает трудные близкие кандидаты

relation можно получать из двух направленных голов: equivalence, generalization, specialization, substitution или contradiction. Отдельную relation-head добавляем только после проверки, что направленные метки качественные и согласованы.

Общая часть делит знания между задачами, а головы не дают одной цели поглотить остальные. Если directional-разметка отсутствует, соответствующий loss пропускается для этой строки, но preservation и ranking продолжают обучаться.

4. Как модель видит подстановку

Для обучения основной режим — два полноценных материализованных текста. Целевая сущность дополнительно отмечается специальными маркерами, чтобы модель не тратила `saracity` на поиск места изменения.

Вход `marked_pair`

A: ... The [E1]National Air Traffic Controllers Association[/E1] ...

B: ... The [E2]FAA[/E2] ...

Что подаём	Почему	Где применяется
Полный A и B	сохраняет дальние зависимости, coreference и доменный контекст	имена собственные, финальная оценка
Маркеры цели	явно показывают изменённый span	все типы сущностей
Короткое окно	дешёвая генерация вокруг числа	DATE/MONEY/PERCENT/QUANTITY

Важно: короткое окно используется только для генерации числовых вариантов. Финальная модель всё равно оценивает восстановленный полный контекст.

Технически в датасете хранятся `left/right` с масками, но перед токенизацией `cross-encoder` материализует `model_left/model_right`: восстанавливает именно нужное упоминание по `mask_idx`, а не первое совпадение строки. Это защищает от ошибок, когда одна сущность встречается в тексте несколько раз.

5. Целевые выходы и принятие решения

Решение не сводится к одному необъяснимому числу. Направленные выходы дают диагностическое объяснение, а основной score используется в приложении.

Выход	Интерпретация
$A \rightarrow B = \text{entailment}$	исходное высказывание поддерживает заменённое
$B \rightarrow A = \text{entailment}$	заменённое высказывание поддерживает исходное
Оба entailment	эквивалентность; кандидат может быть preserved
Только одно направление	обобщение или специализация; не считать alias автоматически

Комбинация	Решение
Оба entailment	высокая вероятность сохранения
Neutral в одном направлении	изменение конкретности; review или changed
Contradiction	фактологически несовместимая замена
Низкий preserve + высокий MLM-fit	приоритетный hard negative

MLM-fit не является семантической меткой: он показывает, насколько кандидат естественен в позиции. Для hard negative нужен именно естественный, но неверный кандидат.

Пример	MLM-fit	Семантический результат
$\text{debt} \rightarrow \text{road}$	может быть высоким из-за локальной формы	не означает сохранение объекта
National Air Traffic Controllers Association $\rightarrow$ NATCA	оба варианта естественны	сохранение при тождестве организации
20 percent $\rightarrow$ 30 percent	оба варианта естественны	изменение факта; numeric changed

6. Разные ветки генерации кандидатов

Общий проверяющий encoder один, но генерация и ограничения зависят от типа сущности.

Ветка	Генерация	Что проверяем
Имена собственные	полный контекст; aliases, аббревиатуры, близкие объекты	тождество объекта и направленное следование
Обычные сущности	ModernBERT retrieval + WordNet; без случайных слов	лексическая взаимозаменяемость в данном контексте
Числа и величины	локальное окно 1–2 слова слева/справа; форматные и близкие изменения	единица, знак, дата, величина и факт
Domain terms	кандидаты из того же домена и документа	не спутать термин с общей сущностью

Для common-пары encoder используется как генератор пула, а не как судья. Морфологические дубли и буквальные совпадения удаляются до обучения.

До формирования пары	проверка	зачем
Строковое равенство	casefold, пробелы, Unicode, нормализация числа	не допустить identity
Морфология	singular/plural и простые окончания	не обучать модель на лёгких негативах
Тип и алфавит	числа, служебные слова, смешанные языки, title-like phrases	снизить шум retrieval
Контекст	кандидат должен воспроизводиться в полном в	не перепутать маску или упоминание

7. Офлайн-пайплайн на H100

На сервере без интернета целевой запуск не зависит от API и агентов. Предыдущие результаты типизации используются как локальные входные файлы.

Шаг	Модуль	Результат
1	SQLite-инвентарь	тексты, маски, упоминания, документы, домены и типы сущностей
2	Локальная генерация	common: encoder/WordNet; numeric: правила короткого окна
3	MLM-fit	естественность исходной и заменённой сущности в контексте
4	Weak/rule labels	кандидатный пул с явной пометкой, что метки не gold
5	Quality gates	identity=0, контексты различаются, нет критических ошибок, disjoint split
6	Cross-encoder	обучение preservation + ranking; затем оценка по срезам

Mistral/OpenRouter не запускаются. Общие сущности сначала идут в bootstrap-пул; сомнительные пары не маскируются под золотую разметку. Локальные артефакты, которые должны быть на сервере до старта: checkpoint ModernBERT, entity_inventory.sqlite, WordNet, сохранённые файлы типизации и текущий proper-name corpus. Пайплайн создаёт новую папку запуска и ничего не удаляет.

8. Как формируется обучающая выборка

В обучение попадают не все сгенерированные строки, а только строки после автоматических инвариантов и явного контроля происхождения метки.

Источник	Роль	Статус
Existing proper-name corpus	основной supervision для preservation	наиболее зрелая часть
Common encoder retrieval	близкие кандидаты для bootstrap и hard-negative mining	weak, требует калибровки
Numeric rules	эквивалентный формат и близкое изменение величины	rule-based, проверяется отдельно
Directional NLI	пара меток A→B и B→A	отдельная разметка; не выводится механически из binary

Для каждого ряда сохраняются entity_id, candidate, text_id, mention_id, domain, entity_type, candidate_kind, источник супервизии и полный контекст. Это позволяет делать честные entity/document-disjoint разбиения.

Текущий фиксированный корпус	Строк	Комментарий
Всего	24 935	12 989 changed; 11 946 preserved
Proper names	24 826	основной зрелый источник
Common existing	109	только 3 preserved; не считать полноценным common train
Numeric	0	добавляется отдельной локальной rule-веткой

9. Функция обучения

На первом этапе оптимизируется бинарная семантическая оценка и ranking. На втором этапе добавляются две направленные NLI-задачи на строках, где такие метки действительно размечены.

$$L = L_{\text{preserve}} + \lambda_{\text{rank}} L_{\text{rank}} + \lambda_{\text{dir}} (L_{A \rightarrow B} + L_{B \rightarrow A})$$

Компонент	Когда включаем	Зачем
L_preserve	сразу	основной production-сигнал
L_rank	сразу для подтверждённых positive/hard-negative групп	не дать модели считать случайные negatives достаточными
L_A→B, L_B→A	после направленной разметки	различать эквивалентность, обобщение и специализацию
MLM-fit	как локальный признак/фильтр	контекстная естественность; не золотая метка

Не подаём в NLI-головы фиктивные labels: changed сам по себе не говорит, было ли противоречие, потеря конкретности или просто другая сущность.

На H100 сначала сравниваем pair, marked_pair и masked_query на одном split. После выбора входа добавляем ranking. Multi-head NLI запускаем отдельной абляцией, чтобы понять, даёт ли он прирост preservation, а не только более красивое объяснение.

10. Что реально запускаем сначала

Полная multi-head архитектура является целевым развитием. Практически её вводим поэтапно, чтобы отделить эффект данных от эффекта усложнения модели.

Этап	Обучение	Критерий перехода
I	одна preservation-head + marked_pair + ranking	macro-F1 и PR-AUC на disjoint test; отдельные срезы proper/common/numeric
II	добавить две направленные NLI-heads	направленная разметка имеет приемлемое agreement и не конфликтует с preserve
III	relation interpretation из двух направлений; при необходимости отдельная relation-head	стабильные классы equivalence/generalization/specialization/contradiction
IV	hard-negative mining моделью	новые близкие negatives улучшают challenge-set без деградации редких типов

Такой порядок оставляет рабочую бинарную модель уже на первом этапе, но не закрывает путь к более глубокой оценке влияния сущности.

Режим H100	Что сохраняем	Что сравниваем
Baseline	текущий proper-name корпус	общий score и calibration
Offline bootstrap	proper + common weak + numeric rules	прирост на common/numeric и риск шума
Multi-head	same split + directional rows	preserve-only против совместного loss

11. Как оцениваем качество

Общая метрика недостаточна: большая proper-name ветка может скрыть провал на числах и common-сущностях.

Срез	Метрики	Что ищем
Общий	macro-F1, PR-AUC, ROC-AUC, calibration	работает ли базовая задача
Тип сущности	proper/common/numeric/domain	не маскируется ли дисбаланс
Тип кандидата	alias, synonym, hard negative, numeric change	какие генераторы полезны
Домен	news/legal/dialogue	переносимость между стилями
Challenge-set	ошибки и confidence	естественные, но неверные подстановки
NLI	macro-F1 по A→B и B→A	согласованность направленных выводов

Разбиение делается по связанным сущностям и документам. Иначе одна и та же организация или статья может попасть и в train, и в test, искусственно завысив результат.

На редких типах (LOC, NORP, GPE) показываем размер выборки и доверительный интервал, а не только F1. Отдельно сохраняем challenge-set из естественных, но неверных замен: именно он показывает, научилась ли модель семантике, а не формальным отличиям.

12. Итоговое решение

Мы строим локальный модуль оценки семантики замены, а не новый суммаризатор.

1	Данные	SQLite-инвентарь и типизация дают полный контроль над сущностью, упоминанием, документом и контекстом
2	Кандидаты	локальные encoder/WordNet/rule-ветки создают разнообразные близкие пары без сетевых вызовов
3	Модель	общий ModernBERT cross-encoder с preservation-head, ranking loss и будущими направленными NLI-heads
4	Решение	двустороннее следование объясняет, сохранился ли объект, обобщилась ли информация или возникло противоречие
5	Контроль	weak-метки не выдаются за gold; качество подтверждается по типам, доменам и challenge-набору

Первый проверяемый результат на H100: binary preservation + ranking на полном disjoint-корпусе. После этого направленная разметка и multi-head обучение добавляются как измеряемое расширение, а не как недоказанное усложнение.

Главный принцип: генератор ищет кандидатов, encoder оценивает пару, а directional heads объясняют направление изменения смысла. Ни один из этих сигналов не заменяет независимую проверку качества данных.