

Оценка семантики заменённых сущностей

Офлайн-разметка, направленное следование и multi-head ModernBERT

1. Задача требует сравнивать утверждения, а не строки

Исходный текст $A = C[e]$ содержит сущность e . После подстановки кандидата c получаем $B = C[c]$. Система должна определить, сохранилось ли фактическое значение утверждения в данном контексте. Это не задача восстановления маски и не новый суммаризатор: меняется ровно одно целевое упоминание, а модель оценивает последствия этой замены.

Класс	Пример	Что требуется понять
Preserved	Federal Aviation Administration $\rightarrow$ FAA	разные написания обозначают ту же организацию; оба текста утверждают одно и то же
Changed	University of Oklahoma $\rightarrow$ University of Hawaii	кандидат грамматически подходит и относится к тому же типу, но меняет референт и факт
Changed	20 percent $\rightarrow$ 30 percent	лексика и структура текста почти не меняются, но меняется числовое утверждение
Uncertain	the university $\rightarrow$ the institution	без более широкого контекста или знания референта нельзя надёжно доказать эквивалентность

Целевой объект обучения — контекст + исходная сущность + кандидат, а не сущность или косинусная близость сами по себе.

2. Одной похожести текстов недостаточно

Два текста могут иметь почти одинаковые эмбединги и различаться одним критическим фактом. Поэтому общая semantic similarity полезна для поиска кандидатов, но не является финальным критерием корректности подстановки.

Сигнал	Что он измеряет	Что он не гарантирует	Роль
Cosine similarity	лексическую и тематическую близость сущностей	тождество объекта и сохранение факта в предложении	retrieval кандидатов
MLM fit	насколько естественно кандидат выглядит в позиции	что кандидат обозначает тот же объект или величину	фильтр грамматики и контекста
Preservation score	сохранилось ли утверждение после замены	направление потери или добавления информации	главная production-оценка
Directional NLI	следует ли B из A и следует ли A из B	качество без направленной разметки	глубокая семантическая диагностика

Hard negative должен одновременно иметь высокий контекстный fit и низкую фактическую эквивалентность. Случайные слова слишком просты, а один высокий cosine иногда возвращает тематически далёкие пары. Поэтому retrieval, MLM и cross-encoder используются как разные оси, а не сворачиваются в один порог.

3. Корпус пока сосредоточен на именах собственных

Канонический корпус после очистки содержит 24 935 бинарных пар: 12 989 changed и 11 946 preserved. Основной объём составляют имена собственные. Разбиение выполняется по связанным компонентам entity + document, поэтому одна исходная сущность и один документ не попадают в разные split.

Ветка	Объём	Статус	Что уже хорошо	Главный риск
Proper names	24 826	основной train	alias, аббревиатуры и близкие подмены по полному контексту	качество зависит от старой LLM-разметки
Common audited	109	challenge	проверенные сложные отрицательные	почти нет положительного класса
Common weak	1 271	bootstrap	795 hard negatives и 476 WordNet-позитивов без identity	WordNet и cosine не гарантируют контекстную эквивалентность
Numeric	0 в corpus	генератор готов	в инвентаре типизировано 3 055 числовых сущностей	правила ещё не прошли финальный аудит и split

Аналитический вывод: нельзя публиковать одну общую метрику как качество на всех сущностях. Proper, common и numeric должны иметь отдельные test/challenge-срезы, а weak common нельзя смешивать с gold без явного признака источника разметки.

4. Офлайн-пайплайн готов к запуску на H100

На сервере не предполагается доступ к Mistral, OpenRouter или Hugging Face Hub. Все необходимые артефакты переносятся заранее: SQLite-инвентарь, локальный checkpoint ModernBERT, tokenizer, WordNet, размеченный proper-корпус и сохранённые snapshot-файлы типов сущностей.

1	Preflight	проверить CUDA, локальность tokenizer/model, Torch, NumPy, NLTK WordNet и наличие всех JSONL/SQLite-файлов
2	Common retrieval	получить кандидатов из инвентаря и WordNet через ModernBERT embeddings; убрать identity и простые singular/plural
3	Numeric rules	изменить число, дату, процент, валюту или формат записи с учётом 1–2 слов слева и справа
4	MLM scoring	посчитать правдоподобие исходной и подставленной сущности в восстановленном контексте
5	Weak labels	явно пометить common как encoder/WordNet weak supervision, numeric как rule-based supervision
6	Quality gates	исключить идентичные входы, конфликты, пропавшие сущности, пересечения документов и сущностей между split
7	Training	обучить baseline и weak-augmented модели на одном фиксированном разбиении и сравнить их по типам

Слова `mistral` или `openrouter` в именах старых snapshot-файлов обозначают источник уже сохранённой типизации. Во время H100-запуска сетевых вызовов нет.

5. Стратегия генерации зависит от типа сущности

Один генератор не подходит для названия организации, обычного существительного и числа. Тип сущности задаёт длину контекста, источник кандидатов и допустимые автоматические метки.

Ветка	Контекст	Генерация кандидатов	Надёжность метки
Proper name	полный восстановленный текст	уже размеченные alias и близкие сущности того же типа/домена	используем существующий audited/reliable корпус
Common entity	несколько предложений вокруг упоминания	ModernBERT neighbors, WordNet synsets и прямые синонимы	только weak label; cosine сам по себе не определяет класс
Domain term	контекст и признак домена	кандидаты из того же домена и WordNet при наличии	особенно нужен отдельный challenge-срез
Numeric	локальное окно для генерации, полный текст для модели	эквивалентный формат или близкое изменение значения/единицы	правило надёжно лишь при корректной типизации числа

Для чисел используется гипотеза, что величина обычно связана с ближайшей сущностью или единицей непосредственно перед либо после неё. Поэтому генератор смотрит короткое окно, но cross-encoder получает полный контекст: локальный шаблон не должен скрывать, что A5, Section 12 или 747 могут быть именем модели, разделом закона или обозначением объекта.

6. Основной вход явно отмечает замену в двух текстах

Для пары строятся два материализованных текста: A с исходной сущностью и B с кандидатом. Целевые span отмечаются специальными токенами, чтобы модель не искала единственное различие по всему длинному документу.

Режим	Вход	Преимущество	Ограничение
pair	полный A + полный B	самое прямое представление задачи	модель должна сама найти изменённый span
marked_pair	A с [E1]...[/E1] + B с [E2]...[/E2]	фокус на конкретной подстановке при сохранении полного контекста	два почти одинаковых длинных текста
masked_query	общий контекст с [TGT] + строки e и c	меньше дублирования токенов	сущности вынесены из естественной позиции

Основной H100-запуск использует marked_pair; pair и masked_query остаются абляциями. mask_idx и candidate-контекст используются для восстановления именно целевого упоминания, что важно, когда одна сущность встречается в документе несколько раз.

На вход модели подаются полноценные тексты, а не тексты с неразрешённым <mask>. Маска используется только на этапе генерации или в отдельной входной абляции.

7. Multi-head модель даёт четыре семантических выхода

Общий ModernBERT кодирует пару A, B и формирует одно представление h. Поверх него обучаются несколько голов. Модель не генерирует список текстовых следствий: она классифицирует, следует ли одно утверждение из другого в той же ситуации.

Голова	Выход	Назначение	Данные
H_preserve	preserved / changed	основная production-оценка допустимости замены	все бинарные пары
H_A→B	entailment / neutral / contradiction	проверить, следует ли изменённый текст из исходного	строки с направленной меткой
H_B→A	entailment / neutral / contradiction	проверить обратное направление и потерю/добавление специфичности	строки с направленной меткой
H_relation	5 типов отношений	диагностика equivalence, generalization, specialization, substitution, contradiction	может выводиться из двух NLI-голов

Ranking не требует отдельной головы: тот же preservation logit используется в pairwise loss. MLM-fit также остаётся отдельным локальным сигналом для отбора кандидатов, а не подменяет семантические головы.

Архитектура допускает частичную разметку: если у строки есть только preserved/changed, обновляется H_preserve; если есть направленные метки, дополнительно обновляются NLI-головы. Это позволяет начать обучение до полной разметки всех задач.

8. Два направления задают пять типов отношений

Обозначим исходный текст как A, а текст после замены как B. Простая метка `changed` сообщает только факт различия, но не объясняет его направление. Комбинация двух NLI-решений даёт более точную структуру ошибки.

A → B	B → A	Отношение	Preserve	Интерпретация
entailment	entailment	equivalence	да	alias, эквивалентная запись числа, контекстный синоним без потери смысла
entailment	neutral	generalization	нет	в менее специфичен; исходное утверждение поддерживает новое, но не наоборот
neutral	entailment	specialization	нет	в добавляет специфичность, которой не было в A
neutral	neutral	substitution	нет	правдоподобная сущность того же типа, но другой объект или факт
contradiction	любое	contradiction	нет	утверждения несовместимы в одной ситуации

Preserved надёжно соответствует взаимному entailment. Обратное неверно для текущих данных: из одного `changed` нельзя понять, была ли это нейтральная подмена, специализация или противоречие. Поэтому направленные метки нельзя механически восстановить для всех старых строк.

9. Multi-task loss использует только доступные метки

Для каждой головы используется своя маска наличия разметки. Это защищает модель от выдуманных NLI-меток и позволяет смешивать proper, common и numeric без требования одинаковой полноты аннотаций.

$$L = \lambda_p \cdot L_{\text{preserve}} + m_{AB} \cdot \lambda_{AB} \cdot L_{\text{NLI}}(A \rightarrow B) + m_{BA} \cdot \lambda_{BA} \cdot L_{\text{NLI}}(B \rightarrow A) + m_{\text{rel}} \cdot \lambda_{\text{rel}} \cdot L_{\text{relation}} + \lambda_r \cdot L_{\text{rank}} + \lambda_c \cdot L_{\text{consistency}}$$

Компонент	На каких данных	Что оптимизирует	Стартовый вес
L _{preserve}	все audited и weak/rule строки	бинарную семантическую сохранность	1.0
L _{NLI}	только направленно размеченная подвыборка	entailment/neutral/contradiction отдельно в обе стороны	0.3 + 0.3
L _{relation}	строки с двумя направленными метками	пять типов отношения между исходным и изменённым утверждением	0.15
L _{rank}	группы с одним контекстом и несколькими кандидатами	позитив выше сложного отрицательного на margin	0.2–0.3
L _{consistency}	строки с двумя NLI-метками	взаимный entailment согласован с высоким preservation score	0.05–0.1

Веса не фиксируются как истина: сначала обучается `n_preserve`, затем `ranking`, затем NLI-головы. Каждое добавление принимается только после абляции на одном split. Weak common можно down-weight по `supervision_quality`, чтобы 1 271 эвристическая пара не искажала более надёжный proper-корпус.

10. Направленные метки добавляются консервативно

В полностью офлайн-режиме нельзя заменить независимую семантическую разметку догадкой. Поэтому направленные головы обучаются только на подмножестве, где отношение выводится надёжно из структуры кандидата или заранее подготовлено до переноса на сервер.

Источник	Какие метки допустимы	Ограничение	Роль
True alias / abbreviation	обычно entailment в обе стороны	нужно исключить неоднозначные и частичные названия	ядро equivalence
Numeric equivalent format	entailment в обе стороны	значение, валюта и единица должны совпадать	чистые positives
Numeric changed value	changed; contradiction только в фиксированном утверждении	не всякая смена числа является логическим противоречием без контекста	preservation и challenge
WordNet relation	часть generalization/specialization	synset и hypernym не гарантируют взаимозаменяемость в предложении	слабая NLI-разметка
Proper hard negative	чаще substitution или contradiction	changed не различает эти классы	требует сохранённой направленной разметки или ручного аудита

Практический вариант для первого H100-запуска: обучить preservation + ranking на всём корпусе, а NLI-головы — на небольшом высокоточном subset. После этого ошибки модели образуют очередь active learning для ручной направленной проверки.

Сейчас точное наложение направленной разметки покрывает 30 train, 3 validation и 5 test строк. Этого достаточно для проверки кода, но недостаточно для выбора модели по NLI-F1.

11. H100-обучение разделено на проверяемые этапы

1	Data preparation	офлайн-генерация common/numeric, MLM-scoring, аудит, сборка фиксированного disjoint-корпуса
2	Binary baseline	marked_pair, только H_preserve, 3–4 эпохи, bf16; зафиксировать общий и типовые thresholds
3	Input ablation	сравнить pair, marked_pair, masked_query на одинаковых train/val/test и выбрать основной вход
4	Ranking	добавить пары positive vs hard negative для одного контекста; проверить прирост именно на сложных отрицательных
5	Multi-head NLI	добавить две направленные и relation-головы с masked loss; encoder и preservation head инициализировать из лучшего checkpoint
6	Weak-data ablation	сравнить без common weak, с полным weak-пулом и с down-weighted weak-пулом
7	Calibration	подобрать пороги preserved/changed и reject-band uncertain на validation, затем один раз оценить test

Стартовая конфигурация: ModernBERT checkpoint, max_length=512, batch_size≈32, bf16, lr=2e-5, без gradient checkpointing на H100 при достаточной памяти. Итоговые параметры выбираются по validation PR-AUC/macro-F1, а не по train loss.

12. Метрики считаются отдельно по типам сущностей

Одна aggregate accuracy скрывает перекося в сторону proper names. Основная таблица результатов строится по задачам, типам сущностей и сложности кандидата.

Основные метрики

- macro-F1 и balanced accuracy для preserved/changed;
- PR-AUC как основная метрика при дисбалансе;
- ROC-AUC как дополнительная ранговая метрика;
- ECE/Brier score для калибровки;
- pairwise ranking accuracy и margin violations;
- macro-F1 для A→B и B→A отдельно.

Обязательные срезы

- proper / common / numeric / domain_term;
- ORG / PERSON / LAW / GPE / DATE / MONEY / PERCENT;
- alias, abbreviation, close entity, synonym, hard negative;
- news, multi-news, legal, dialogue;
- gold/audited против weak/rule supervision;
- короткий против длинного контекста.

Критерий пригодности — не только рост общего F1. Модель должна удерживать proper-name качество, заметно улучшить common/numeric challenge и не решать задачу по формальным признакам типа длины кандидата, регистра или источника данных.

13. Production-скоринг объединяет три независимых ответа

Для каждого кандидата система восстанавливает оба текста и получает набор интерпретируемых оценок. Финальное решение не обязано сводиться к одной вероятности без объяснения причины.

Шаг	Выход	Как используется	Что возвращаем
MLM	$\text{fit}(c)$	отсеять грамматически разрушенные и явно случайные кандидаты	контекстная правдоподобность
Preservation	$P(\text{preserved})$	основное решение о допустимости подстановки	score + calibrated label
Directional NLI	$P(A \rightarrow B), P(B \rightarrow A)$	объяснить потерю или добавление информации	relation type
Calibration	threshold + reject band	не заставлять модель отвечать на неуверенных случаях	preserved / changed / uncertain

Пример результата: кандидат может иметь высокий MLM-fit, низкий preservation score и отношение substitution. Это хороший hard negative: текст звучит естественно, но обозначает другой объект. Для alias ожидаются высокий preservation score и взаимный entailment.

Отдельно логируются entity_type, candidate_kind, domain и длина контекста. Эти поля нужны не модели ради модели, а для мониторинга дрейфа и понимания, на каких типах замен падает качество.

14. Риски контролируются quality gates и абляциями

Риск	Как проявляется	Контроль
Weak-label noise	WordNet-позитив формально связан, но неверен в конкретном тексте	down-weight, отдельный источник, ручной calibration sample, абляция без weak
Лёгкие negatives	модель учит нерелевантность вместо фактической ошибки	MLM-fit, same-type retrieval, ranking и challenge-набор
Leakage	та же сущность или документ появляется в train и test	connected-component split по entity и document
Multi-head conflict	preservation и NLI-головы дают несовместимые ответы	consistency loss, masked labels и отчёт disagreement
Domain shortcut	модель связывает класс с legal/news источником	метрики по доменам и балансирование источников
Overconfidence	неверные ответы с высокой вероятностью	temperature scaling и reject-band uncertain

Multi-head архитектура оправдана только если directional heads улучшают challenge-набор или дают полезную диагностику без деградации главной задачи. Если этого нет, production остаётся на более простой preservation + ranking модели.

15. Надёжное ядро предшествует направленной семантике

Целевое решение — общий ModernBERT cross-encoder с основной головой сохранения смысла, ranking loss и двумя направленными NLI-головами. Такой дизайн различает эквивалентность, обобщение, специализацию, замену объекта и противоречие, но не требует полной разметки всех голов для каждой строки.

На сопоставимой rgorer-pate выборке из 1 479 пар обновлённая бинарная модель подняла macro-F1 с 0,635 до 0,690, то есть на 5,5 п.п. Это подтверждает ценность расширенного корпуса, но ещё не измеряет качество common, numeric и направленных голов.

Этап	Результат	Условие перехода
Сейчас	24 935 пар, binary baseline и multi-head trainer	binary улучшен; все головы и masked losses проверены локальным smoke-test
Далее	preservation + ranking	hard-negative PR-AUC растёт без деградации alias positives
После	две directional NLI-головы	есть высокоточная направленная подвыборка и отдельный NLI challenge
Финал	калиброванный multi-head scorer	согласованные головы, стабильность по доменам и понятный reject-band

Главный принцип: энкодеры дешёво находят кандидатов, MLM проверяет уместность, cross-encoder оценивает сохранение факта, а направленные головы объясняют, какую информацию замена потеряла или добавила.